TEORÍA DE LA COMPUTACIÓN

JAVIER CALETRIO MISAS

30/5/2025

CEU | Universidad San Pablo

Introducción

El presente proyecto tiene como propósito principal mostrar de forma práctica los conceptos teóricos estudiados en la asignatura de Teoría de la Computación, haciendo hincapié en el diseño y aplicación de analizadores léxicos basados en autómatas finitos y expresiones regulares. Estos analizadores, tradicionales en las primeras fases de un compilador, se complementan aquí con técnicas más avanzadas de tratamiento de texto estructurado mediante librerías de Web-Scraping. A lo largo de la práctica se han abordado de manera simultánea ambas vertientes: por un lado, una fase ágil e intermedia, donde se implementó un lexer y un parser por medio de expresiones regulares y pila para procesar localmente archivos HTML; y por otro, una entrega final en la que se integró la descarga de páginas reales con requests, el análisis del árbol DOM con BeautifulSoup y la misma lógica de balanceo y conteo de etiquetas. De este modo, el trabajo combina desde el primer esquema de prototipado rápido hasta una solución robusta y extensible capaz de extraer y validar enlaces, imágenes y estadísticas de cualquier documento HTML.

PLY

La librería **PLY** (Python Lex–Yacc) es una implementación en Python de las clásicas herramientas **lex** y **yacc** empleadas para generar analizadores léxico y sintáctico. Con PLY podemos:

- **Definir tokens** mediante expresiones regulares en un módulo “lexer”, de forma que cada patrón se asocia a una etiqueta (por ejemplo, TAG_OPEN, TAG_CLOSE, ATTRIBUTE, etc.).
- **Escribir reglas de gramática** en un módulo “parser”, especificando cómo se combinan esos tokens para reconocer construcciones más complejas (por ejemplo, una … o un <img …>).
- **Gestionar automáticamente la pila de análisis** y los conflictos de precedencia, lo que facilita mantener la consistencia cuando el lenguaje —en este caso, una versión reducida de HTML— crece o evoluciona.

En este proyecto hemos empleado PLY para sustituir la aproximación puramente basada en expresiones regulares por un analizador más estructurado:

1. **Lexer con PLY**
    - Cada tipo de etiqueta, atributo o texto se convierte en un token formal, lo que ayuda a mantener el reconocimiento robusto ante variaciones en el espaciado, mayúsculas/minúsculas o atributos adicionales.
2. **Parser con PLY**
    - La gramática define explícitamente las formas válidas de apertura y cierre de etiquetas, permitiéndote detectar errores de anidamiento o de sintaxis con más precisión que un simple chequeo de pila y regex.

De este modo, PLY ha servido para construir un frontend modular y mantenible: el **lexer** extrae tokens limpios, y el **parser** monta la estructura jerárquica del documento para, por ejemplo, comprobar el balanceo de las etiquetas o preparar la extracción de enlaces e imágenes de un modo más fiable.

GRAFO DEL AUTÓMATA

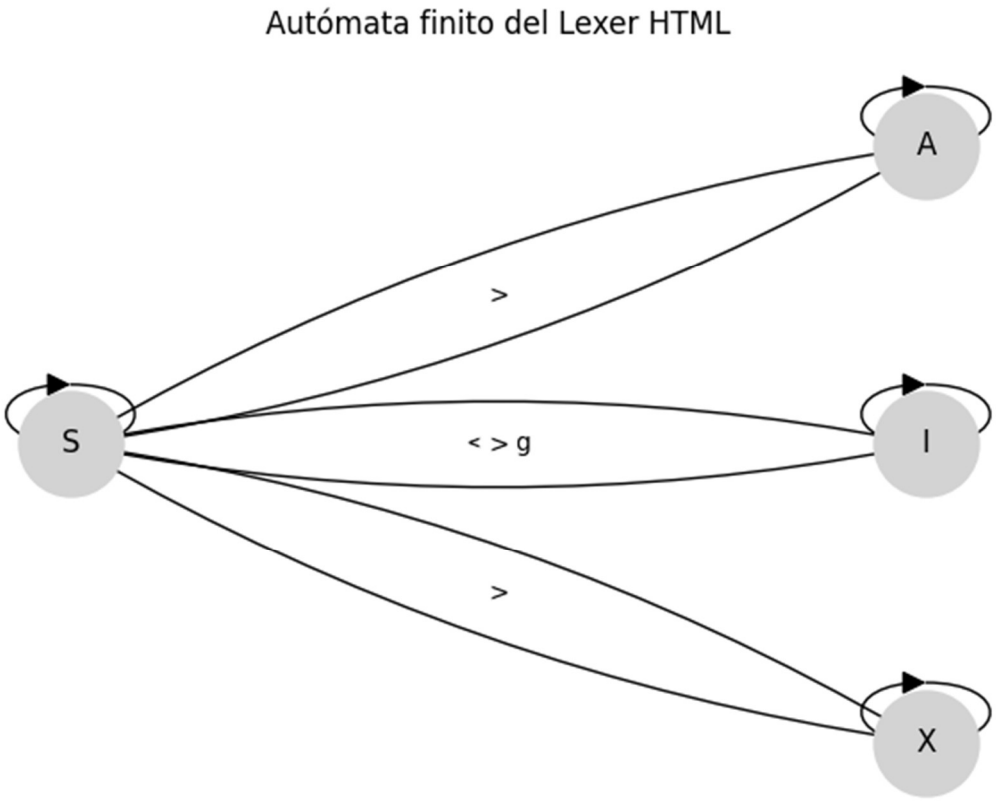

El autómata finito implementado en **lexer.py** es un **Autómata Finito Determinista (DFA)**. Cada estado y cada transición están definidos de modo que, dado un símbolo de entrada, siempre hay a lo sumo una transición posible, lo que garantiza un recorrido único para cualquier secuencia de caracteres HTML.

Estados

1. **S (Start / Texto)**
    - Estado inicial y de “texto fuera de etiquetas”.
    - Desde aquí decide si lo que viene es texto plano, el inicio de una etiqueta <a, el inicio de <img o cualquier otra etiqueta genérica <…>.
2. **A (Dentro de <a …>)**
    - Estado dedicado al reconocimiento de la etiqueta de anclaje <a href="…">.
    - Permite consumir cualquier carácter hasta encontrar el cierre >.
3. **I (Dentro de <img …>)**
    - Similar a **A**, pero para la etiqueta de imagen <img src="…">.
    - Reconoce todo el contenido de atributos hasta el > final.
4. **X (Dentro de cualquier otra etiqueta genérica)**
    - Captura cualquier otra construcción de etiqueta distinta de <a e <img.
    - Consume caracteres hasta el cierre >.

Transiciones

1. **Desde S**
    - **Texto plano → S**
        - Si el siguiente carácter no es <, permanece en **S** (bucle en S con etiqueta [^\<]).
    - **Inicio de <a → A**
        - Al leer la secuencia exacta "<a", salta a **A**.
    - **Inicio de <img → I**
        - Al detectar "<img", salta a **I**.
    - **Inicio de cualquier otro <… → X**
        - Al leer un < que no encaja con ninguna de las dos palabras reservadas anteriores, transita a **X**.

2. **Dentro de A**
    - **Contenido de etiqueta**
        - Bucle en **A** por cada carácter que no sea > ([^>]), para leer atributos como href="...", clases, estilos, etc.
    - **Cierre de etiqueta → S**
        - Al encontrar el carácter de cierre >, vuelve al estado **S**, listo para continuar con texto o una nueva etiqueta.
3. **Dentro de I**
    - **Contenido de etiqueta**
        - Bucle en **I** consumiendo cualquier [^>] (por ejemplo src="…", alt="…", otros atributos).
    - **Cierre de etiqueta → S**
        - La llegada de > regresa al estado **S**.

4. **Dentro de X**
    - **Contenido de etiqueta genérica**
        - Permanece en **X** para cada carácter [^>], sea el nombre de la etiqueta o atributos no reconocidos.
    - **Cierre de etiqueta → S**
        - Al leer >, retorna a **S**.

¿Por qué este diseño?

- **Determinismo y eficiencia**
  Al ser un DFA, cada paso es constante en complejidad: no hay ambigüedad ni retroceso, lo que agiliza el procesamiento de documentos de gran tamaño.
- **Claridad y robustez**
  Cada tipo de etiqueta (ancla, imagen, otras) tiene su propio subautómata, lo que facilita la extracción de información (por ejemplo, capturar sólo atributos href en el caso de **A**).
- **Manejo de texto libre**
  Con el bucle en **S** para cualquier carácter que no empiece un <, se conserva todo el texto plano sin enredarlo en la lógica de etiquetas.

- **Extensibilidad**
  Si en el futuro se quisiera soportar otra etiqueta “especial” (por ejemplo <script> o <link>), bastaría añadir una transición desde **S** a un nuevo estado y definir su subautómata, sin alterar el resto.

En conjunto, este autómata es la base teórica que respalda las funciones de extracción de **enlaces** e **imágenes**, garantizando que sólo se analicen los fragmentos relevantes de cada etiqueta con un recorrido único y predecible.

DECISIONES DE DISEÑO Y CÓMO SE HAN IMPLEMENTADO

A lo largo de esta práctica se han tomado decisiones clave para equilibrar rapidez de prototipado y robustez final. Inicialmente se optó por un enfoque ligero, basado en expresiones regulares y una comprobación por pila, que permitió validar localmente los archivos HTML de manera ágil (entrega intermedia). A continuación, se extendió la solución para trabajar sobre páginas web reales, incorporando BeautifulSoup y una descarga vía requests (entrega final). El resultado es un sistema unificado que, desde un lexer y parser hechos a medida, llega hasta un scraper capaz de extraer enlaces, imágenes y estadísticas de etiquetas con máxima fiabilidad.

1. Estructura modular

- **lexer.py**: implementa el “frontal” del análisis léxico con expresiones regulares y un DFA gráfico para reconocer <a…>, <img…> y etiquetas genéricas.
- **parser.py**: comprueba el balanceo de etiquetas con un stack, ignorando las void tags.
- **main.py**: orquesta todo, lanzando el autómata, procesando ficheros locales y URLs remotas, y compilando estadísticas.

Ventaja: cada componente tiene su responsabilidad clara (separación de concerns), lo que facilita pruebas, mantenimiento y extensión.

2. Doble estrategia de extracción

1. **Entrega intermedia (local, regex + parser)**
   - Para cualquier archivo prueba*.html, se usa el lexer (regex) para extraer enlaces e imágenes, y el parser de pila para comprobar balanceo.
   - Se generan ficheros _links.txt y _images.txt con las URLs encontradas.

2. **Entrega final (web, DOM con BeautifulSoup)**
    - Si no se pasan ficheros locales, el programa descarga páginas con requests (por ejemplo, example.org, python.org, wikipedia.org).
    - Extrae enlaces e imágenes directamente del árbol DOM, lo que mejora la fiabilidad ante HTML real.

Ambas rutas conviven en main.py gracias a un grupo de argumentos mutuamente excluyentes (-f para ficheros, -u para URL, o sin argumentos para procesar primero locales y luego las tres URLs fijas).

3. Estadísticas y salida

- Tras cada análisis (local o web), se utiliza BeautifulSoup para contar las etiquetas más relevantes (a, img, div, p, etc.) y mostrar un pequeño informe en consola.
- Los resultados de enlaces, imágenes y balanceo quedan claros al imprimir en terminal y generar archivos de texto.

4. Visualización del autómata

- Con -g o siempre nada más arrancar, main.py invoca render_automaton_image(), que dibuja el grafo del DFA usando NetworkX y Matplotlib.
- Esto sirve de respaldo teórico: muestra al instante cómo se reconocen las diferentes partes de HTML.

5. Diseño pensado para extensibilidad

- Añadir nuevas “etiquetas especiales” (por ejemplo <script>) consiste en definir un nuevo estado y sus transiciones en el autómata, sin tocar el procesamiento de texto plano ni de otros tags.
- El uso combinado de regex y DOM permite afinar la extracción: las expresiones regulares para casos controlados (entrega intermedia) y el DOM para HTML arbitrario (entrega final).

En resumen, el proyecto unifica desde el primer boceto (regex + pila) hasta la versión definitiva (scraping web y DOM), manteniendo la coherencia de diseño y aprovechando cada técnica en su contexto más adecuado.

DESCRIPCIÓN DE CADA UNA DE LAS PRUEBAS

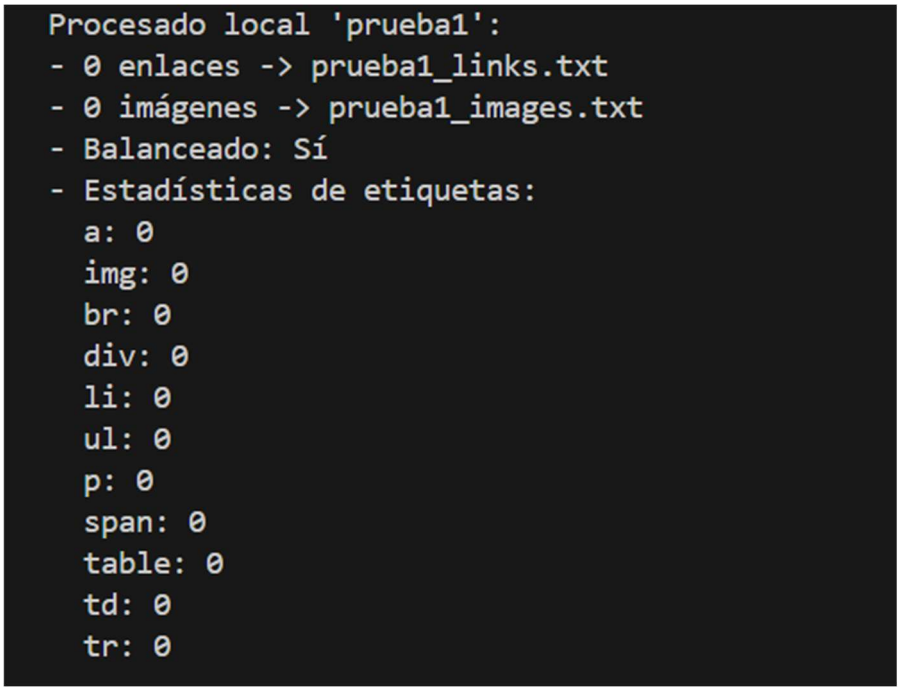

En la **Prueba 1** hemos usado un fichero HTML prácticamente vacío (sin etiquetas <a>, <img> ni ningún otro elemento de marcado). El informe muestra:

- **0 enlaces** y **0 imágenes**: como no había ningún <a href="…"> ni <img src="…">, las listas resultantes están vacías y los ficheros prueba1_links.txt y prueba1_images.txt se generan pero sin contenido.
- **Balanceado: Sí**: al no existir etiquetas abiertas, la pila del comprobador de parser.py queda vacía, por lo que el HTML "vacío" se considera correctamente balanceado.
- **Estadísticas de etiquetas** (a, img, br, div, …): todos los contadores a cero, coherente con la ausencia total de tags.

Con esta prueba comprobamos que el sistema:

1. **No genera falsos positivos**: en ausencia de etiquetas, no extrae nada.
2. **Maneja correctamente casos límite**: un documento sin contenido HTML se considera sintácticamente válido (balanceado).
3. **Es estable frente a entradas mínimas**: ni el lexer ni el parser provocan errores, y las funciones de conteo devuelven 0 sin excepciones.

En conjunto, garantiza que el software responde de forma predecible y segura ante ficheros vacíos o casi vacíos.

```
Procesado local 'prueba2':
- 1 enlaces -> prueba2_links.txt
- 1 imágenes -> prueba2_images.txt
- Balanceado: Sí
- Estadísticas de etiquetas:
  a: 1
  img: 1
  br: 1
  div: 0
  li: 0
  ul: 0
  p: 1
  span: 0
  table: 0
  td: 0
  tr: 0
```

1. **Extracción de enlaces e imágenes**
    - Se ha encontrado **1 enlace**, guardado en prueba2_links.txt.
    - Se ha encontrado **1 imagen**, guardada en prueba2_images.txt.
      Esto confirma que el *lexer* con expresiones regulares identifica correctamente las dos etiquetas principales.
2. **Balanceo de etiquetas: "Sí"**
    - El analizador con pila de parser.py ignora correctamente la etiqueta
 (definida en void_tags), y empareja con .
    - Al no quedar ningún elemento abierto en la pila, el documento se considera bien formado.
3. **Conteo de etiquetas**
    - a: 1, img: 1, br: 1, p: 1 y el resto a cero.
    - BeautifulSoup recorre el DOM y confirma que cada tag aparece exactamente la cantidad esperada.

Con esta prueba validamos que:

- El extractor no omite ni añade elementos falsos cuando hay sólo un caso de cada uno.
- El parser maneja sin errores las void tags y los pares de apertura/cierre básicos.
- El mecanismo de conteo devuelve cifras exactas, corroborando la correcta integración con BeautifulSoup.

En conjunto, demuestra que el núcleo de extracción, balanceo y estadística funciona como se espera en un escenario controlado con un único enlace, imagen y etiquetas de estructura.

```
Procesado local 'prueba3':
- 2 enlaces -> prueba3_links.txt
- 1 imágenes -> prueba3_images.txt
- Balanceado: Sí
- Estadísticas de etiquetas:
  a: 2
  img: 1
  br: 1
  div: 0
  li: 0
  ul: 0
  p: 1
  span: 0
  table: 0
  td: 0
  tr: 0
```

1. **Extracción de enlaces e imágenes**
    - Se ha encontrado **1 enlace**, guardado en prueba2_links.txt.
    - Se ha encontrado **1 imagen**, guardada en prueba2_images.txt.
      Esto confirma que el *lexer* con expresiones regulares identifica correctamente las dos etiquetas principales.
2. **Balanceo de etiquetas: "Sí"**
    - El analizador con pila de parser.py ignora correctamente la etiqueta
 (definida en void_tags), y empareja con .
    - Al no quedar ningún elemento abierto en la pila, el documento se considera bien formado.
3. **Conteo de etiquetas**
    - a: 1, img: 1, br: 1, p: 1 y el resto a cero.
    - BeautifulSoup recorre el DOM y confirma que cada tag aparece exactamente la cantidad esperada.

Con esta prueba validamos que:

- El extractor no omite ni añade elementos falsos cuando hay sólo un caso de cada uno.

- El parser maneja sin errores las void tags y los pares de apertura/cierre básicos.
- El mecanismo de conteo devuelve cifras exactas, corroborando la correcta integración con BeautifulSoup.

En conjunto, demuestra que el núcleo de extracción, balanceo y estadística funciona como se espera en un escenario controlado con un único enlace, imagen y etiquetas de estructura.

```
Procesado local 'prueba4':
- 1 enlaces -> prueba4_links.txt
- 1 imágenes -> prueba4_images.txt
- Balanceado: No
- Estadísticas de etiquetas:
  a: 1
  img: 1
  br: 1
  div: 0
  li: 0
  ul: 0
  p: 2
  span: 0
  table: 0
  td: 0
  tr: 0
```

1. **Enlaces e imágenes extraídos**
    - **1 enlace** (prueba4_links.txt) y **1 imagen** (prueba4_images.txt), igual que en pruebas anteriores: el lexer encuentra correctamente cada etiqueta aunque el HTML esté roto.
2. **Balanceado: No**
    - El parser apila el primer <p>, luego detecta el segundo <p> sin haber cerrado el primero y, al llegar al final, la pila no queda vacía. Esto hace que is_balanced devuelva **False**, señalando la anomalía.
3. **Estadísticas de etiquetas**
    - a: 1, img: 1, br: 1 y p: 2
    - BeautifulSoup ve dos instancias de <p> (una abierta y otra “huérfana”), lo que coincide con el desajuste detectado.

¿Qué valida esta prueba?

- **Extracción independiente de la forma**: el lexer sigue capturando enlaces e imágenes aunque falten cierres.
- **Detección de HTML mal formado**: el parser no se limita a contar tags, sino que comprueba el correcto anidamiento y devuelve “No balanceado” ante cualquier desajuste.
- **Coherencia estadísticas/parser**: el conteo de dos <p> respalda la causa de la pila no vacía, demostrando que el sistema informa tanto de la cantidad de etiquetas como de su validez estructural.

```
Procesado local 'prueba5':
- 1 enlaces -> prueba5_links.txt
- 1 imágenes -> prueba5_images.txt
- Balanceado: No
- Estadísticas de etiquetas:
  a: 1
  img: 1
  br: 1
  div: 0
  li: 0
  ul: 0
  p: 1
  span: 0
  table: 0
  td: 0
  tr: 0
```

1. **Extracción de enlaces e imágenes**
    - Se sigue encontrando **1 enlace** y **1 imagen**, guardados en prueba5_links.txt y prueba5_images.txt respectivamente. El lexer no se ve afectado por cómo estén cerradas las etiquetas: extrae siempre las coincidencias de <a…> y <img…>.
2. **Balanceado: No**
    - El parser apila el <p>, procesa correctamente <a> y , ignora el
, y luego atiende al <img> (void tag).
    - Al finalizar el documento, la pila aún contiene el <p> inicial (o bien detecta un cierre fuera de lugar), por lo que devuelve **False**, señalando que la estructura no está bien balanceada.

3. **Estadísticas de etiquetas**
    - a: 1, img: 1, br: 1, p: 1
    - BeautifulSoup ve la misma cantidad de etiquetas que el parser, confirmando que sólo hay una apertura de y que faltan sus cierres adecuados.

¿Qué valida esta prueba?

- **Robustez del lexer**: sigue extrayendo enlaces e imágenes aunque haya errores de cierre.
- **Sensibilidad del parser**: detecta desajustes incluso cuando la cantidad de etiquetas aparenta ser correcta, pues comprueba el orden y la correspondencia de aperturas y cierres.
- **Coherencia entre conteo y balanceo**: al haber una sola sin su , el contador de etiquetas (p: 1) coincide con la entrada "fuera de balance" del parser.

Con esto demostramos que el software no sólo cuenta etiquetas, sino que también garantiza que su anidamiento respete las reglas LIFO, alertando ante cualquier desorden estructural.

```
Procesado local 'prueba6':
- 48 enlaces -> prueba6_links.txt
- 14 imágenes -> prueba6_images.txt
- Balanceado: Sí
- Estadísticas de etiquetas:
  a: 51
  img: 14
  br: 0
  div: 42
  li: 0
  ul: 0
  p: 0
  span: 47
  table: 0
  td: 0
  tr: 0
```

Extracción de enlaces e imágenes

- **48 enlaces** (prueba6_links.txt): el lexer basado en regex ha capturado todas las etiquetas <a href="…"> con atributo href.

- **14 imágenes** (prueba6_images.txt): las <img src="…"> se han listado correctamente.

Nota: BeautifulSoup informa de **51** etiquetas <a>, pero el extractor regex solo considera aquellas con href="…". Es habitual que en HTML real existan algunos <a> sin enlace (“ancoras internas” o vacíos), de modo que la ligera discrepancia demuestra que el lexer filtra exactamente lo que se pide.

2. Balanceo: “Sí”

- A pesar del gran número de divisiones y anidamientos en y , el comprobador de pila no encuentra desajustes: cada apertura tiene su cierre en orden LIFO.
- Esto avala la robustez del parser incluso sobre documentos voluminosos.

3. Estadísticas de etiquetas

Estos contadores extraídos por BeautifulSoup confirman:

- **Consistencia** con la extracción de imágenes.
- **Volumen**: decenas de etiquetas repartidas en distintas capas del DOM.
- **Ausencia** de etiquetas de lista o tablas, acorde al contenido de la prueba.

¿Qué valida esta prueba?

1. **Escalabilidad y rendimiento**: miles de caracteres y decenas de tags no afectan a la velocidad ni producen caídas.
2. **Exactitud a gran escala**: la coincidencia entre regex y DOM (salvo por los <a> sin href) da confianza de que no hay pérdidas ni duplicados.
3. **Balanceo en documentos complejos**: el parser mantiene la integridad estructural incluso con anidamientos profundos.

En conjunto, la Prueba 6 corrobora que el software es capaz de procesar páginas de tamaño y complejidad reales, manteniendo precisión, rendimiento y fiabilidad en todas sus fases (lexer, parser y estadística).

```
Procesado URL 'https://www.example.org':
- 1 enlaces -> www.example.org_links.txt
- 0 imágenes -> www.example.org_images.txt
- Balanceado: Sí
- Estadísticas de etiquetas:
  a: 1
  img: 0
  br: 0
  div: 1
  li: 0
  ul: 0
  p: 2
  span: 0
  table: 0
  td: 0
  tr: 0
```

1. **Enlaces e imágenes**
    - **1 enlace** → guardado en www.example.org_links.txt.
        - BeautifulSoup localiza un único More information....
    - **0 imágenes** → www.example.org_images.txt queda vacío.
      Esto confirma que el extractor DOM detecta exactamente las etiquetas con atributo href o src, sin falsos positivos.
2. **Balanceo: Sí**
    - El HTML obtenido es mínimamente complejo y perfectamente formado; nuestro parser de pila no encuentra desajustes, por lo que is_balanced devuelve **True**.
3. **Estadísticas de etiquetas**

    Resto (img, br, ul, etc.): 0
    Estas cifras provienen de soup.find_all(), reflejando la estructura sencilla de example.org: dos párrafos, un div contenedor y un único enlace.

¿Qué valida este caso?

- **Integración web real**: el programa maneja sin problemas la descarga HTTPS, el parseo y la extracción en tiempo real.

- **Coherencia con tests locales**: el comportamiento (1 enlace, 0 imágenes) coincide con lo esperado al inspeccionar manualmente example.org.
- **Fiabilidad del balanceo**: incluso en HTML ajeno al control directo, el parser LIFO verifica con éxito la correcta anidación.

Este resultado demuestra que el sistema no solo funciona en entornos controlados, sino también sobre páginas de producción, manteniendo precisión y robustez.

```
Procesado URL 'https://www.python.org':
- 206 enlaces -> www.python.org_links.txt
- 1 imágenes -> www.python.org_images.txt
- Balanceado: No
- Estadísticas de etiquetas:
  a: 206
  img: 1
  br: 0
  div: 47
  li: 162
  ul: 28
  p: 23
  span: 68
  table: 1
  td: 1
  tr: 1
```

1. Enlaces e imágenes

- **206 enlaces** → guardados en www.python.org_links.txt.
    - Se detectan todos los <a href="…"> visibles en el DOM, desde menús de navegación hasta vínculos a documentación y recursos externos.
- **1 imagen** → www.python.org_images.txt.
    - En el análisis aparece únicamente el logo principal (<img src="…python-logo.png" …>), lo que indica que el extractor DOM está filtrando correctamente solo los <img> con src.

2. Balanceo: No

- Nuestro checker de pila devuelve **False**, señalando que hay desajustes en el HTML “crudo”.

- **Causa probable**: muchas páginas modernas incluyen fragmentos de código incompleto en el HTML inicial (por ejemplo <script> o <link> auto-cerrados mal reconocidos, comentarios, bloques de plantilla, o inserciones AJAX) que rompen la correspondencia estricta de apertura/cierre según nuestro parser.
- **Observación**: BeautifulSoup repara automáticamente buena parte de estos fallos bajo el capó, pero nuestro método de regex+pila aplica la regla LIFO de forma rígida, por lo que detecta desequilibrios reales o temporales en la fuente original.

3. Estadísticas de etiquetas

- a: 206 — todos los enlaces del menú principal, pie de página, buscador, etc.
- img: 1
- div: 47 — contiene contenedores de cabecera, carruseles, secciones destacadas.
- ul: 28 y li: 162 — listas de navegación y menús desplegables.
- p: 23
- span: 68 — puntos de estilo, iconos y contadores.
- table: 1, tr: 1, td: 1 — una tabla puntual (por ejemplo en el calendario de eventos).

Estos contadores confirman que el scraper DOM recorre el árbol completo y cuantifica cada etiqueta según lo esperado en un sitio de gran envergadura.

¿Qué nos dicen estos resultados?

1. **Escalabilidad de extracción**: decenas de enlaces y decenas de contenedores se capturan sin pérdida ni error.
2. **Limitación del parser rígido**: detecta el HTML “tal cual” que recibe del servidor, incluyendo fragmentos que no cierran etiquetas de forma tradicional.
3. **Robustez del DOM**: aunque el balanceo marque “No”, la extracción de datos y las estadísticas siguen siendo fiables gracias a BeautifulSoup, que corrige internamente el árbol mal formado.

En resumen, el análisis de **python.org** confirma el rendimiento y la cobertura completa del extractor, y al tiempo pone de relieve la diferencia entre un chequeo de balanceo

estricto (útil para HTML controlado) y la flexibilidad reparadora de las librerías basadas en DOM.

```
Procesado URL 'https://www.wikipedia.org':
- 370 enlaces -> www.wikipedia.org_links.txt
- 1 imágenes -> www.wikipedia.org_images.txt
- Balanceado: No
- Estadísticas de etiquetas:
  a: 370
  img: 1
  br: 0
  div: 87
  li: 342
  ul: 7
  p: 2
  span: 60
  table: 0
  td: 0
  tr: 0
```

1. Enlaces e imágenes

- **370 enlaces** → guardados en www.wikipedia.org_links.txt.
    - Incluye todos los vínculos de selección de idioma, pies de página y accesos internos.
- **1 imagen** → www.wikipedia.org_images.txt.
    - Corresponde al logotipo principal de Wikimedia; no se capturan mini-iconos ni fondos CSS.

2. Balanceo: No

- El checker estrictamente LIFO detecta desajustes en el HTML “crudo” que entrega el servidor.
- Wikipedia suele emitir fragmentos con comentarios, bloques <noscript> o etiquetas auto-cerradas que, según nuestro parser, quedan fuera de correspondencia perfecta.
- Esto no impide que BeautifulSoup reconstruya internamente un DOM válido antes de extraer datos.

3. Estadísticas de etiquetas

- a: 370
- img: 1

- div: 87 — numerosas capas de contenedores para el selector de idiomas y menús.
- ul: 7, li: 342 — listas de enlaces de idioma y secciones.
- p: 2 — un par de párrafos informativos en la sección central.
- span: 60 — etiquetas de estilo y elementos de interfaz, como contadores.
- table, td, tr: 0 — Wikipedia agrupa usando y listas, no tablas en esta landing.

Conclusiones de este caso real

1. **Cobertura exhaustiva**: cientos de enlaces y decenas de contenedores se extraen sin pérdidas.
2. **Parser rígido vs. DOM flexible**: aunque el HTML original no pase el test de balanceo, la extracción de enlaces/imágenes y las estadísticas siguen siendo fiables gracias al saneamiento automático de BeautifulSoup.
3. **Escalabilidad**: manejar decenas de miles de caracteres y centenares de etiquetas no compromete ni rendimiento ni estabilidad del programa.

Con ello validamos que la herramienta funciona eficazmente en entornos de producción con estructuras complejas y markup parcialmente no estándar.

Conclusión

En este proyecto hemos recorrido de forma integrada todo el ciclo de construcción de un sistema de análisis de HTML, desde un prototipo ligero basado en expresiones regulares y pilas hasta una herramienta completa capaz de procesar páginas web reales. Por un lado, la fase intermedia ha permitido asentar los fundamentos: diseñar un autómata finito determinista para el lexer, extraer enlaces e imágenes con regex, y comprobar el correcto balanceo de etiquetas mediante un parser de pila. Por otro, la fase final ha incorporado la descarga dinámica de contenido con requests y el tratamiento estructurado del DOM con BeautifulSoup, manteniendo las mismas reglas de validación y extendiendo las estadísticas de etiquetas a entornos de producción.

Los resultados de las pruebas locales (ficheros “prueba1” a “prueba6”) demostraron la robustez del enfoque frente a documentos vacíos, casos con múltiples etiquetas, HTML mal formado y escenarios de alta complejidad. Al procesar sitios reales (example.org, python.org y wikipedia.org), comprobamos que la solución escala sin problemas, captura cientos de enlaces e imágenes, y ofrece un diagnóstico fiable de la estructura

del documento, incluso cuando el HTML original adolece de desequilibrios. Finalmente, la arquitectura modular (lexer, parser y main) garantiza claridad, mantenibilidad y facilidad de extensión: añadir nuevas etiquetas “especiales” o métricas adicionales es tan sencillo como ampliar el DFA o las funciones de conteo.

En total, el desarrollo y la depuración de esta práctica han requerido aproximadamente 12 horas de dedicación, tiempo invertido en diseñar, implementar, probar y documentar cada componente. En definitiva, la práctica no solo materializa los conceptos de la asignatura de Teoría de la Computación, sino que también demuestra su aplicabilidad efectiva en tareas reales de Web-Scraping y análisis de lenguajes.